2026

ANALYSE DES VENTES WALMART ET MODÉLISATION PRÉDICTIVE

RAPPORT D'AVANCEMENT DE PROJET

Membres de l'équipe :

- WASSILA ENNOUAR
- SALSABIL REGRAGUI
- MOHAMED LAMINE ZOUTAT
- FARID BANDOUI
- ABDENNOUR KERROUCH
- ANIS HEMAIDA

SOMMAIRE

Message principal et synthèse exécutive 1

Introduction – Contexte et problématique 2

Méthodes – Données et démarche adoptée 3

Résultats – Analyses réalisées 4

Discussion – Premiers enseignements 5

Prochaines étapes 6

MESSAGE PRINCIPAL ET SYNTHÈSE EXÉCUTIVE

01

1. MESSAGE PRINCIPAL ET SYNTHÈSE EXÉCUTIVE

Message principal

Ce projet vise à concevoir un système intelligent de prévision des ventes Walmart, capable d'anticiper les ventes hebdomadaires par magasin et par département afin d'améliorer la gestion des stocks, la planification des promotions et les décisions d'approvisionnement. Les analyses réalisées révèlent une forte hétérogénéité des ventes, une saisonnalité marquée avec des pics en fin d'année, et un effet promotionnel positif mais variable selon les départements.

Ces constats orientent des recommandations concrètes :

- Adapter les stocks par segment
- Anticiper les périodes de forte demande
- Cibler les promotions sur les départements les plus sensibles

DATASET TRAIN	MAGASINS	DÉPARTEMENTS	COUVERTURE
421 570	**45**	**81**	**143**
lignes × 16 colonnes	Types A, B et C	actifs sur 99	semaines (2010–2012)

Conclusions clés de la Phase 1

- **Saisonnalité forte et reproductible :** les ventes hebdomadaires suivent un cycle annuel très marqué, avec un pic en novembre-décembre (Thanksgiving/Noël) et un creux en janvier. Ce pattern est stable d'une année à l'autre, ce qui est un atout majeur pour la prévision.
- **La taille du magasin est le premier prédicteur :** la variable Size (et Type A/B/C) est le meilleur prédicteur linéaire des ventes. Les magasins de Type A concentrent la majorité du chiffre d'affaires avec les plus fortes amplitudes saisonnières.
- **Loi de Pareto sur les départements :** environ 20-25 % des départements génèrent ~80 % du chiffre d'affaires total. Cette concentration guide la priorisation de la modélisation.
- **Thanksgiving est l'événement commercial le plus impactant,** suivi du Super Bowl. L'indicateur IsHoliday seul est insuffisant — des indicateurs spécifiques par fête sont nécessaires.
- **Les promotions (MarkDown) ont un effet positif confirmé,** mais hétérogène selon le département et le type de magasin. MarkDown1 et MarkDown5 semblent les plus impactants.
- **Le dataset est propre et prêt pour la modélisation** après traitement de 1 285 ventes négatives (0,30 %) et imputation des MarkDown manquants à 0.

INTRODUCTION – CONTEXTE ET PROBLÉMATIQUE

02

2. INTRODUCTION – CONTEXTE ET PROBLÉMATIQUE

Contexte du projet

La grande distribution est un secteur hautement concurrentiel où la capacité à **anticiper la demande** constitue un avantage stratégique majeur. Walmart, en tant que leader mondial du commerce de détail, génère chaque semaine des volumes considérables de données transactionnelles à travers ses 45 magasins répartis dans différentes régions des États-Unis.

Le projet **SIPV (Système Intelligent de Prévision des Ventes)** vise à concevoir et déployer un pipeline complet de science des données pour prédire les ventes hebdomadaires de Walmart à la granularité Store × Département × Semaine, en exploitant des données historiques enrichies de variables contextuelles.

Problématique et enjeux

- Une **rupture de stock** signifie une vente perdue et une dégradation de l'expérience client.
- Un **surstock** génère des coûts de stockage, des démarques et des destructions de marchandise.
- Les **promotions non ciblées** diluent les marges sans générer de croissance des ventes.
- Les **décisions d'achat** mal calibrées désynchronisent l'approvisionnement de la demande réelle.

Objectifs du projet

N°	Objectif analytique	KPI cible
O1	Prévision des ventes hebdomadaires par magasin et département	Précision > 85 %
O2	Identification des facteurs influençant les ventes (promotions, fêtes, économie)	Importance des variables
O3	Aide à la décision : stocks, promotions, achats fournisseurs	ROI +15 %, ruptures -20 %

Structure du projet

Le projet est structuré en **trois grandes phases** :

(1) **Compréhension et Préparation des Données** — exploration, nettoyage et ingénierie des variables

(2) **Modélisation et Évaluation Prédictive** — entraînement, optimisation et comparaison des modèles

(3) **Intelligence Décisionnelle et Exploitation** — interprétation des résultats et recommandations stratégiques.

MÉTHODES – DONNÉES ET DÉMARCHE ADOPTÉE

3.1 Description des données
3.2 Pipeline de préparation des données

03

3. MÉTHODES – DONNÉES ET DÉMARCHE ADOPTÉE

3.1 Description des données

Le projet repose sur trois fichiers CSV fournis par Walmart, couvrant la période de **février 2010 à juillet 2013** :

Fichier	Description	Dimensions
train.csv	Ventes hebdomadaires par magasin et département (variable cible : Weekly_Sales)	421 570 lignes
features.csv	Variables contextuelles : température, carburant, CPI, chômage, MarkDown 1–5	8 190 lignes
stores.csv	Caractéristiques des magasins : type (A, B, C) et superficie (Size)	45 lignes

Après jointure des trois fichiers (train + features + stores) sur les clés Store, Date et IsHoliday, le dataset consolidé contient **421 570 observations × 16 variables** pour la phase d'entraînement.

Variable	Type	Description
Store	category	Identifiant du magasin (1–45)
Dept	category	Identifiant du département (81 actifs)
Date	datetime64	Début de la semaine de vente
Weekly_Sales	float64	Chiffre d'affaires hebdomadaire en $ — **variable cible**
IsHoliday	bool	Indicateur de semaine de fête (Super Bowl, Thanksgiving, Noël, Labour Day)
Temperature	float64	Température régionale moyenne (°F)
Fuel_Price	float64	Prix du carburant dans la région ($/gallon)
MarkDown 1–5	float64	Montants promotionnels par type (disponibles à partir de nov. 2011)
CPI	float64	Indice des prix à la consommation par région
Unemployment	float64	Taux de chômage régional (%)
Type	category	Catégorie du magasin : A (grand), B (moyen), C (petit)
Size	int64	Superficie du magasin (sq ft)

3.2 Pipeline de préparation des données

La préparation des données s'est déroulée en six étapes successives, documentées dans le notebook Jupyter (sections 1.3.1 à 1.3.7) :

1. Importation et jointure	Chargement des trois fichiers CSV et jointure LEFT sur les clés Store × Date × IsHoliday. Résultat : dataset unifié de 421 570 lignes × 16 colonnes.
2. Vérification de la complétude	Contrôle des dimensions, inventaire des doublons (aucun détecté) et validation de la structure globale du dataset.
3. Harmonisation des formats	Conversion de Date en datetime64, de Store/Dept/Type en category, et vérification que les variables numériques sont en float64.
4. Identification des incohérences	Détection de 1 285 ventes négatives (0,30 %), de valeurs promotionnelles négatives dans MarkDown2 (1 311) et MarkDown3 (257), et validation des plages de toutes les variables.
5. Traitement des valeurs manquantes	Imputation des MarkDown1–5 manquants à 0 (absence réelle de promotions avant nov. 2011). Suppression des lignes avec MarkDown négatifs. Résultat : 0 valeur manquante résiduelle.
6. Gestion des valeurs aberrantes	35 521 outliers détectés dans Weekly_Sales (8,43 %). Décision : conservation des outliers car ils représentent des ventes réelles et légitimes (pics de fêtes, grands magasins).

Bilan qualité des données

Après nettoyage : **421 570 lignes × 16 colonnes**, zéro valeur manquante sur les variables critiques, tous les types correctement harmonisés. La seule particularité notable est l'absence de données MarkDown avant novembre 2011, traitée par imputation à 0 (absence réelle, non aléatoire).

RÉSULTATS – ANALYSES RÉALISÉES

4.1 Analyse descriptive des ventes
4.2 Tendances temporelles et saisonnières
4.3 Impact des promotions (MarkDown)
4.4 Impact des périodes de fêtes
4.5 Variables économiques et contextuelles
4.6 Corrélations et sélection de features

04

4.1 Analyse descriptive des ventes

L'analyse exploratoire a été conduite sur l'ensemble du dataset TRAIN, couvrant 45 magasins, 81 départements et 143 semaines (février 2010 à octobre 2012).

Statistiques descriptives de la variable cible (Weekly_Sales)

Indicateur	Valeur	Interprétation
Moyenne	~15 981 $	Tirée vers le haut par les grands magasins et départements
Médiane	~7 612 $	Distribution fortement asymétrique à droite
Minimum	0 $ (après nettoyage)	Ventes nulles sur certains départements inactifs
Maximum	~693 099 $	Grands magasins type A lors des périodes de fêtes
Écart-type	~22 711 $	Très forte dispersion — CV > 100 %

Répartition des ventes par type de magasin

Les trois catégories de magasins (A, B, C) présentent des performances très différenciées :

Type	Nb magasins	Part du CA total	Ventes moy. hebdo	Caractéristique
A	22	~72 %	Élevées	Grands magasins — forte amplitude saisonnière
B	17	~22 %	Moyennes	Magasins intermédiaires — performance stable
C	6	~6 %	Faibles	Petits magasins — distribution resserrée

Concentration du chiffre d'affaires par département L'analyse par département révèle une **loi de Pareto très marquée** : environ **20–25 % des départements génèrent ~80 % du chiffre d'affaires total**. Le dataset compte 81 départements actifs, avec une forte hétérogénéité interne : certains départements (épicerie générale, jardinage) concentrent une part disproportionnée des ventes, tandis que de nombreux départements affichent une contribution marginale (<1 % du CA). Cette disparité impose de traiter chaque combinaison Store × Département comme une entité distincte dans la modélisation.

Point clé — Implications pour la modélisation

La forte asymétrie de Weekly_Sales (moyenne >> médiane) et la dispersion élevée confirment qu'un modèle global unique sera insuffisant. Une approche segmentée par type de magasin et/ou par département est recommandée pour améliorer les performances prédictives.

4.2 Tendances temporelles et saisonnières

L'analyse de la dimension temporelle des ventes a permis d'identifier plusieurs dynamiques clés qui guideront la construction des features pour la modélisation.

Pattern observé	Description	Impact sur la modélisation
Cycle annuel fort	Pic marqué en novembre-décembre, creux en janvier. Reproductible d'une année à l'autre.	Le mois et la semaine de l'année sont des features essentielles.
Creux estivaux	Les mois de juin à août affichent systématiquement des niveaux de ventes plus bas.	Feature "trimestre" ou "saison" à créer.
Pics de fêtes	Hausse significative lors de Thanksgiving, Noël et Super Bowl.	Indicateurs spécifiques par fête recommandés.
Stabilité inter-annuelle	Le profil saisonnier est remarquablement stable entre 2010, 2011 et 2012.	Fort potentiel de prévision — la saisonnalité est appris facilement.
Hétérogénéité dept.	Les profils saisonniers varient fortement d'un département à l'autre.	Interaction Département × Mois à capturer dans les modèles.

Recommandation pour le feature engineering

Créer les features temporelles suivantes : mois, semaine de l'année, trimestre, année, distance à la prochaine fête (semaines avant), indicateur par fête (one-hot : SuperBowl, LaborDay, Thanksgiving, Christmas). L'interaction Département × Mois pourrait également significativement améliorer les performances.

4.3 Impact des promotions (MarkDown)

Les cinq variables MarkDown (1 à 5) représentent les réductions de prix temporaires appliquées par Walmart. Elles ne sont disponibles qu'à partir de **novembre 2011**, couvrant ainsi seulement ~40 % de la période d'étude.

Constat	Résultat	Décision
Valeurs manquantes	50 à 64 % selon le MarkDown	Imputées à 0 (absence réelle)
Effet promotionnel global	Lift positif confirmé sur la moyenne et la médiane	Conserver les 5 variables séparément
Hétérogénéité des effets	Certains depts : lift > 50 %. D'autres : effet marginal ou négatif	Créer des features d'interaction HasPromo × Dept
MarkDowns les plus impactants	MarkDown1 et MarkDown5 montrent les plus forts effets	Prioriser dans la sélection de features
Biais temporel	Promotions concentrées avec les fêtes → confusion possible	Modéliser avec contrôle de la saisonnalité

4.4 Impact des périodes de fêtes

L'analyse approfondie de l'impact des 4 fêtes majeures Walmart (Super Bowl, Labour Day, Thanksgiving, Christmas) confirme leur rôle majeur comme facteur d'influence des ventes.

Fête	Lift moyen estimé	Profil temporel	Implication
■ Thanksgiving	Plus fort de tous	Pic aigu + Black Friday immédiat	Feature prioritaire — pondération élevée recommandée
■ Super Bowl	Élevé	Pic concentré sur la semaine	Achats alimentaires / divertissement
■ Christmas	Modéré	Étalé sur 3–4 semaines en amont	Feature "distance à Noël" à créer
■ Labour Day	Faible à modéré	Pic ponctuel limité	Indicateur binaire suffisant

Un résultat particulièrement intéressant est l'effet temporel élargi : certaines fêtes (notamment Thanksgiving et Noël) génèrent une hausse des ventes 1 à 2 semaines avant l'événement lui-même, reflétant les achats préparatoires des consommateurs. La semaine suivant la fête affiche souvent une chute brutale, caractéristique d'un effet de report de consommation. Ce pattern d'anticipation devra être capturé par des features de distance temporelle aux fêtes.

4.5 Variables économiques et contextuelles

Les quatre indicateurs économiques (température, prix du carburant, CPI, taux de chômage) présentent des corrélations linéaires faibles avec les ventes, mais leurs effets sont néanmoins présents à travers des relations non linéaires ou conditionnelles.

Variable	Corrélation avec ventes	Nature de la relation	Utilité pour la modélisation
Temperature	Faible	Non linéaire — proxy de saisonnalité	Utile comme variable contextuelle
Fuel_Price	Très faible	Indicateur macroéconomique indirect	Variable de contexte économique
CPI	Faible à modérée	Bimodale — proxy géographique	Capte le pouvoir d'achat local (attention à la multicolinéarité)
Unemployment	Faible négative	Relation négative attendue, effet structurel	Feature de contexte géographique et économique

4.6 Corrélations et sélection de features

L'étude des corrélations (Pearson et Spearman) entre toutes les variables et Weekly_Sales a permis d'établir un classement des features par pouvoir prédictif.

Rang	Feature	Corrélation Pearson	Priorité de modélisation
1	Size (superficie du magasin)	Forte positive	■ Haute — meilleur prédicteur linéaire
2	Type de magasin (A/B/C)	Forte (via Size)	■ Haute — variable structurelle essentielle
3	Features temporelles (mois, semaine)	Modérée (non linéaire)	■ Haute — capturent la saisonnalité
4	Indicateurs de fêtes (par événement)	Faible globale, forte locale	■ Haute — effet concentré et asymétrique
5	MarkDown1 et MarkDown5	Faible à modérée	■ Moyenne — promotions impactantes
6	CPI et Unemployment	Très faible	■ Moyenne — contexte géographique
7	Temperature et Fuel_Price	Très faible	■ Faible — proxy de saisonnalité

DISCUSSION – PREMIERS ENSEIGNEMENTS

5.1 Enseignements pour la modélisation
5.2 Recommandations opérationnelles préliminaires
5.3 Livrable intermédiaire : tableau de bord Streamlit

05

5. DISCUSSION – PREMIERS ENSEIGNEMENTS

Les analyses de la Phase 1 ont permis de dégager plusieurs enseignements stratégiques directement exploitables pour la modélisation prédictive et pour les décisions opérationnelles.

5.1 Enseignements pour la modélisation

- **Un modèle global unique sera insuffisant.** La forte hétérogénéité intra-magasin et inter-département impose soit une approche segmentée (un modèle par type de magasin), soit l'utilisation d'un modèle à effets croisés intégrant les interactions Store × Dept.
- **La saisonnalité est le facteur dominant.** Les patterns temporels (mois, semaine, indicateurs de fêtes) sont les features les plus prometteuses. Le gradient boosting et les forêts aléatoires sont bien adaptés à ce type de relations non linéaires.
- **La pondération des semaines de fêtes est critique.** La métrique WMAE (Weighted Mean Absolute Error) avec un poids de 5 pour les semaines fériées est alignée avec l'importance commerciale de Thanksgiving et Noël.
- **Les MarkDown nécessitent un traitement particulier.** Leur absence avant novembre 2011 est une absence réelle (imputée à 0), et leurs effets sont hétérogènes selon le département. Conserver les 5 variables séparément est recommandé.

5.2 Recommandations opérationnelles préliminaires

Sur la base des analyses réalisées, trois axes de recommandations ont été identifiés :

R1 — Gestion des stocks	Calibrer les niveaux de stock par type de magasin (A, B, C). Concentrer les efforts sur les top 20 départements (~80 % du CA). Mettre en place un stock de sécurité différencié par combinaison Store × Dept.
R2 — Périodes de fêtes	Constituer les stocks de Thanksgiving 3 à 4 semaines à l'avance. Prioriser les magasins Type A (amplitudes les plus fortes). Identifier les départements les plus sensibles par type de fête.
R3 — Optimisation promotionnelle	Cibler les promotions sur les départements à fort lift promotionnel historique. Éviter les promotions dans les départements à faible réactivité. Estimer le ROI attendu avant le lancement.

5.3 Livrable intermédiaire : tableau de bord Streamlit

Un tableau de bord interactif Streamlit a été développé pour permettre aux décideurs d'explorer visuellement l'ensemble des résultats du projet. Il comprend 7 pages interactives couvrant : la vue d'ensemble des KPIs, les tendances temporelles, les performances par type de magasin, l'impact promotionnel, les jours fériés, les variables économiques et la matrice de corrélations.

PROCHAINES ÉTAPES

06

6. PROCHAINES ÉTAPES

La Phase 1 (Compréhension et Préparation des Données) est complétée. Les travaux en cours portent sur la **Phase 2 : Modélisation et Évaluation Prédictive**, organisée en quatre étapes :

Phase 2 — En cours

• 2.1 Préparation des données pour la modélisation
— Encodage des variables catégorielles (one-hot, target encoding pour Store/Dept)
— Création des features temporelles et contextuelles (mois, semaine, indicateurs de fêtes, distance aux fêtes)
— Séparation des jeux d'entraînement et de validation

• 2.2 Développement et entraînement des modèles
— Sélection des algorithmes : Régression linéaire (baseline), Random Forest, Gradient Boosting (XGBoost/LightGBM)
— Entraînement sur les données historiques (2010–2012)
— Ajustement des hyperparamètres par cross-validation

• 2.3 Évaluation et validation des performances
— Métriques : MAE, RMSE, WMAE (poids 5× pour les semaines fériées)
— Comparaison des performances des modèles
— Analyse des erreurs et interprétation SHAP

• 2.4 Validation métier des prévisions
— Vérification de la cohérence des prévisions avec l'historique
— Validation par les utilisateurs métier

Phase 3 — À venir

• 3.1–3.5 Intelligence Décisionnelle
— Déploiement du modèle de prévision et documentation
— Génération des prévisions par magasin et département
— Système de recommandations pour la gestion des stocks et des promotions
— Simulateur d'impact promotionnel avec estimation du ROI
— Dashboard de monitoring et de visualisation

Synthèse des livrables

Partie 1 : Compréhension et Préparation des Données — complétée.

Partie 2 : Modélisation et Évaluation Prédictive — modèles entraînés et évalués.

Partie 3 : Intelligence Décisionnelle — recommandations et dashboard opérationnels.